Metodologias para extração de conhecimento

Mineração de Dados e Aprendizado de Máquina

28 de setembro de 2026

1 Introdução

Mineração de dados (*Data Mining*) em geral se refere a uma etapa do processo de descoberta do conhecimento (*Knowledge Discovery*). Essa é a fase em que os padrões em um conjunto de dados são identificados e enumerados.

De forma geral, esse processo de descoberta de conhecimento pode ser dividido em sete etapas:

1. **Compreensão do problema** e dos objetivos a serem alcançados. Dentro do jargão científico, é aqui que são elaboradas as hipóteses sobre o objeto a ser estudado.

2. **Seleção** de um conjunto de dados relevantes. Quando deseja-se trabalhar com grandes quantidades de dados, pode ser interessante extrair uma amostra de tamanho menor para realizar os primeiros testes e só posteriormente partir para análise do conjunto completo.

3. Então, um **pré-processamento** é aplicado (uma normalização, uma remoção de ruídos, por vezes esta etapa é referida como uma limpeza dos dados).

4. A seguir, os dados são **transformados**, potencialmente para uma representação mais adequada para posterior aplicação de modelos de reconhecimento de padrões. É aqui que entram etapas como redução de dimensionalidade.

5. **Mineração dos dados**. É aqui que entra a aplicação dos modelos que discutimos nas últimas semanas.

6. Passa-se então para a **avaliação e interpretação** dos resultados da etapa anterior. Note que, inclusive, esta etapa pode levar a uma revisão da etapa 1. Ou seja, o processo de extrair conhecimento não é necessariamente linear, já que uma vez que foi realizada a mineração esta pode contradizer as hipóteses levantadas no começo, demandando que as mesmas sejam repensadas. Além disso, lembre-se sempre do seguinte: os dados são compreendidos através dos modelos, por isso a compreensão dos modelos é essencial para compreender os dados.

7. O **pós-processamento** é então extremamente dependente dos objetivos. Por exemplo, em uma pesquisa científica essa etapa pode ser a de enquadrar o objeto de interesse dentro da literatura existente e então redigir um artigo. Para tarefas de automação (potencialmente realizadas por empresas), o que vem a seguir é o *deployment* de um sistema computacional para o usuário final.

Você pode ler mais sobre as metodoligas KDD, CRISP-DM e SEMMA no seguinte artigo: *KDD, SEMMA and CRISP-DM: a parallel overview* por A. Azevedo e M. F. Santos. (Nota: este artigo é bem curto e descritivo, então creio que valha a pena uma leitura).

2 Tarefas

Você e seu grupo devem escolher dois conjuntos de dados para análise. Atente-se para o seguinte:

- Se existem múltiplos atributos contínuos no seu modelo, qualquer conjunto deles pode ser analisado via regressão linear. Isso ajuda a entender como estas variáveis se relacionam.

- Se existem múltiplos atributos categóricos no seu modelo, qualquer conjunto deles pode ser analisado via árvores de decisão (incluindo modelos que agregam múltiplas árvores). Através das estruturas determinadas para estas, é possível compreender melhor a relação entre estas variáveis.

- Se os atributos contínuos coexistem com os atributos categóricos, perceba que cada atributo categórico define um problema de classificação em função dos atributos contínuos. Assim, esses são os modelos adequados para compreender a relação entre atributos contínuos e discretos.

Escolhidos os seus conjuntos, faça as análies cabíveis para os mesmos seguindo as recomendações destacadas acima. Você não precisa testar todos os modelos vistos em aula, mas, se não o fizer, justique suas escolhas apontando porque estas são adequadas e dispensam o teste de outros modelos.

De acordo com o processo descrito na seção anterior, explique no que consistiu cada uma destas dentro do seu trabalho. Dê bastante atenção ao passo 6, já que é nesta etapa onde seu conhecimento sobre os dados e sobre modelo será sintetizado. O passo 7 é opcional.

Ao final, escreva um relatório com suas observações e apresente seus experimentos e análises para o resto da turma.