UNIVERSIDADE ESTADUAL PAULISTA “JÚLIO DE MESQUITA FILHO”
INSTITUTO DE GEOCIÊNCIAS E CIÊNCIAS EXATAS CAMPUS RIO CLARO

Disciplina de Mineração e Aprendizado de Máquina

Relatório do Trabalho 1

Bacharelado em Ciências da Computação - UNESP/RC

Guilherme Zorzam
João Vitor Beliziário
Julia Machado Miranda
Ygor Ismael

Docente:
Emilio Bergamim Júnior

Rio Claro
2026

Sumário

Sumário **2**
Resumo **3**
1. Introdução **4**
1.1 Hipóteses 4
2. Dados **5**
2.1 Pulsares 5
2.2 Meteoritos 6
3. Metodologia **6**
4. Resultados: pulsares **8**
5. Resultados: meteoritos **12**
6. Discussão **15**
7. Limitações **16**
8. Conclusão **16**
9. Referências Bibliográficas **17**

Resumo

Em pulsares o modelo aprende física; em meteoritos ele aprende quem estava observando. Este trabalho percorre as etapas do processo de descoberta de conhecimento (KDD) sobre duas bases astronômicas de perfis opostos: HTRU2, com 17.898 candidatos a pulsar e 9,2% de positivos, e Meteorite Landings, da NASA, com 45.716 registros. Cada base parte de quatro hipóteses explícitas, testadas com Regressão Logística, LDA/QDA, Naive Bayes, KNN, SVM, MLP, árvores e Random Forest, sempre com AUC-PR e recall como métricas principais.

Em pulsares, a separação é quase linear: SVM linear e Logística (AUC-PR 0,933 no teste) empatam estatisticamente com o MLP, e o limite de desempenho está em pulsares fracos que os oito atributos não capturam. Em meteoritos, uma Random Forest atinge AUC-PR 0,888 para prever se o meteorito foi visto caindo, mas apenas 0,323 usando só massa e família mineralógica; o poder preditivo vem de quando e onde o registro foi feito. Duas hipóteses foram refutadas e reformuladas: o viés temporal teve sentido oposto ao previsto, e a super-representação de metálicos só aparece depois de remover a Antártida (paradoxo de Simpson).

1. Introdução

Um bom desempenho preditivo não garante uma conclusão válida sobre o fenômeno estudado, e este trabalho usa duas bases de astronomia para mostrar a diferença. O estudo foi feito para a disciplina de Mineração de Dados e Aprendizado de Máquina, cuja proposta pede percorrer as etapas do KDD (hipóteses, seleção, pré-processamento, transformação, mineração e, principalmente, avaliação e interpretação), com os modelos vistos em aula.

As bases foram escolhidas por serem opostas. HTRU2 é um problema "limpo", com atributos contínuos derivados do próprio sinal e a pergunta física o que distingue um pulsar de interferência? Meteorite Landings é mista e suja, e o registro de cada meteorito depende de alguém estar olhando, o que cria forte viés de observação.

1.1 Hipóteses

Cada base começa com quatro hipóteses (H1 a H4), que os notebooks tentam confirmar ou refutar. Quando uma é refutada, ela é reformulada, voltando da etapa 6 à etapa 1 do KDD.

Base	Hipótese
Pulsares	H1: o perfil de pulso integrado é mais pontiagudo nos pulsares
Pulsares	H2: o perfil integrado (IP) separa melhor as classes que a curva DM-SNR (DM)
Pulsares	H3: a separação entre as classes é quase linear
Pulsares	H4: a acurácia é enganosa sob desbalanceamento
Meteoritos	H1: há viés de observação, espacial e temporal
Meteoritos	H2: a Antártida forma um cluster de pequenos *Found*
Meteoritos	H3: meteoritos vistos caindo (*Fell*) são mais massivos
Meteoritos	H4: metálicos são super-representados entre os *Found*

2. Dados

As duas bases diferem em origem, tamanho, tipo de atributo e desafio principal.

	Pulsares (HTRU2)	Meteoritos (NASA)
Fonte	UCI ML Repository, id 372	NASA Open Data, *Meteorite Landings*
Registros	17.898 candidatos	45.716
Atributos	8 contínuos (estatísticas do sinal)	massa, ano, lat/lon, classe mineralógica (461 valores), `fall`
Alvo	pulsar vs. ruído (9,2% positivos)	*Fell* vs. *Found* (2,4% *Fell*)
Desafio	desbalanceamento, redundância	viés de observação, dados categóricos e sujos

2.1 Pulsares

A base não tem nulos nem duplicatas, e nenhuma linha foi removida. Um classificador que sempre responde "ruído" tem 90,8% de acurácia e recall zero. Há dois blocos de atributos muito redundantes: ip_kurt–ip_skew (r ≈ 0,95) e dm_kurt–dm_skew (r ≈ 0,92). Os outliers da classe positiva são o próprio sinal, então não foram removidos.

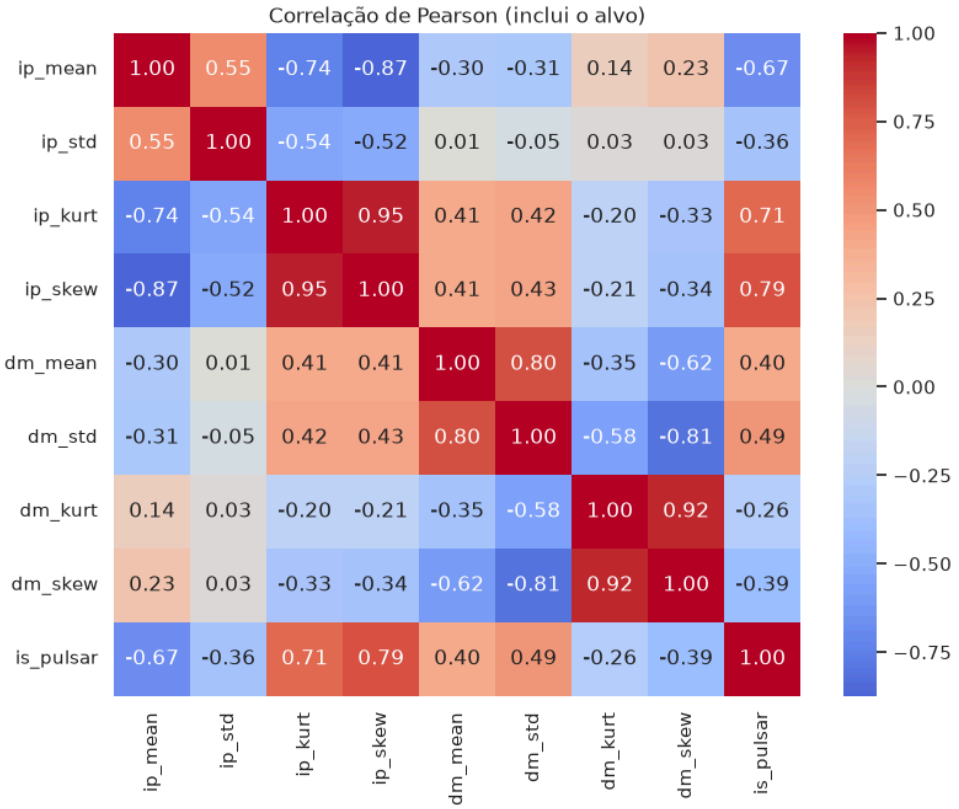


Figura 1. Mapa de correlação de Pearson entre os oito atributos de HTRU2 e o alvo (is_pulsar). Os blocos ip_kurt–ip_skew (0,95) e dm_kurt–dm_skew (0,92) são os pares redundantes citados no texto. Fonte: elaborada pelos autores.

2.2 Meteoritos

A limpeza foi mais pesada: 7.315 registros sem coordenadas e outros 6.214 em (0, 0), valor usado como placeholder de "desconhecido". Também há uma longitude de 354° e 19 massas iguais a zero. Os 461 valores de recclass foram agrupados em 8 famílias mineralógicas, uma simplificação nossa que afeta os resultados por família. Os Fell são 2,4% do total e 10,9% fora da Antártida.

3. Metodologia

O protocolo evita vazamento de dados e escolhe métricas que não escondem o desbalanceamento.

- **Divisão:** treino/teste estratificado 80/20 e validação cruzada estratificada de 5 folds.
- **Vazamento**: escalonamento e transformações ficam dentro de Pipeline, ajustados só no treino de cada fold.
- **Métricas:** AUC-PR e recall como principais, com AUC-ROC, precisão e acurácia como apoio. A acurácia isolada é enganosa nas duas bases.
- **Limiar de decisão:** escolhido com previsões out-of-fold do treino, sem olhar o teste.
- **Modelos:** Regressão Logística, LDA/QDA, Naive Bayes (com e sem Yeo-Johnson), KNN, SVM (linear e RBF), MLP, árvores de decisão e Random Forest. Os modelos de aula não usados têm justificativa no notebook de modelagem.
- **Pulsares:** PCA sem rótulos para testar a separabilidade linear, análise de margem rígida com C alto e regressão entre atributos (curtose em função da assimetria) com bases linear, polinomial e RBF.
- **Meteoritos:** modelagem de fall sem a Antártida, onde a latitude determina o rótulo sozinha. Testes de Mann-Whitney, regressão de

log10(massa) com controles e comparação de conjuntos de atributos (completo, só contexto, só meteorito).

Etapas do KDD no trabalho

A proposta pede que se explique em que consiste cada uma das sete etapas, com mais atenção ao passo 6. A tabela mostra o que foi feito em cada base

Etapa	Pulsares (HTRU2)	Meteoritos (NASA)
1. Compreensão do problema	Hipóteses H1 a H4 sobre forma do pulso, IP vs. DM, separabilidade linear e acurácia	Hipóteses H1 a H4 sobre viés de observação, Antártida, massa e metálicos
2. Seleção	Base completa, 17.898 candidatos	45.716 registros; modelagem de `fall` só com georreferenciados e sem Antártida
3. Pré-processamento	Sem nulos nem duplicatas; outliers mantidos por serem o sinal	Remoção de coordenadas ausentes ou em (0, 0), longitude inválida e massas nulas; agrupamento de `recclass` em 8 famílias
4. Transformação	Escalonamento em `Pipeline`, PCA, Yeo-Johnson, base polinomial e RBF	`log10(massa)`, discretização em época, faixa de massa e hemisfério, codificação das famílias
5. Mineração	Logística, LDA/QDA, Naive Bayes, KNN, SVM, MLP, árvore e Random Forest	Regressão linear, Logística, árvore categórica e Random Forest
6. Avaliação e interpretação	Seção 4: AUC-PR, limiar, coeficientes, perfil dos erros	Seção 5: o modelo aprende o viés; duas hipóteses refutadas e reformuladas
7. Pós-processamento (opcional)	Recomendação da Logística e do limiar conforme o custo dos erros	Apenas esboçado: validar o "esforço de busca" com densidade populacional ou datas de expedições

A etapa 6 é onde o conhecimento sobre os dados e sobre os modelos é sintetizado. Nela os resultados voltaram à etapa 1 duas vezes: a H1 temporal e a H4 dos meteoritos foram refutadas e reformuladas depois de se identificar o confundidor (seção 5). Como os dados são compreendidos através dos modelos, cada interpretação acima parte do que o modelo aprendeu, e não só de seu escore.

Tipos de atributo e modelos escolhidos

A proposta associa cada tipo de atributo a uma família de modelos, e o trabalho cobre as três.

Situação na proposta	Onde foi aplicada
Atributos contínuos: regressão linear	Pulsares: curtose em função da assimetria (IP e DM). Meteoritos: `log10(massa)` em função de `fell`, ano e família
Atributos categóricos: árvores de decisão e ensembles	Meteoritos: ganho de informação e árvore sobre época, faixa de massa, hemisfério e família; Random Forest
Contínuos com categóricos: classificação	Meteoritos: `fall` em função de massa, ano, coordenadas e família. Pulsares: classe em função dos 8 atributos contínuos

Justificativa dos modelos não utilizados

A proposta dispensa testar todos os modelos desde que as escolhas sejam justificadas.

- **Pulsares, árvores e ensembles:** usados só como referência, porque não há atributos categóricos.
- **Pulsares, SVM polinomial e sigmoide:** o kernel RBF cobre o caso não linear; o polinomial é instável com caudas longas e muito mais lento.
- **Pulsares, SVM de margem rígida:** não tem solução, porque os dados não são linearmente separáveis (seção 4).
- **Pulsares, Softmax e SVM One-vs-One:** o problema é binário.
- **Meteoritos, SVM, KNN e MLP:** os atributos são mistos (one-hot mais coordenadas geográficas sem métrica euclidiana natural). As árvores lidam bem com isso e produzem regras legíveis, que é o objetivo do passo 6.
- **Meteoritos, PCA:** há apenas 4 atributos contínuos de naturezas diferentes (massa, tempo, espaço), e uma combinação linear deles não tem interpretação física.

4. Resultados: pulsares

As quatro hipóteses se confirmaram, a H3 com ressalva: os dados são quase linearmente separáveis, não perfeitamente.

Hipótese	Resultado	Evidência principal
H1: perfil mais pontiagudo	Confirmada	Mediana da assimetria ≈ 2,96 (pulsar) vs. 0,19 (ruído); curtose ≈ 11,6 vs. 0,12

Hipótese	Resultado	Evidência principal
H2: IP mais informativo que DM	Confirmada	AUC-PR univariada média 0,78 (IP) vs. 0,38 (DM)
H3: separação quase linear	Confirmada, aproximada	Melhor linear 0,924 vs. melhor não linear 0,929 de AUC-PR
H4: acurácia enganosa	Confirmada	Acurácia 0,980 com recall 0,835; baseline "sempre ruído" tem 90,8%

H1 e H2: onde está o sinal

O ruído fica perto de zero, como um sinal sem pico, e os pulsares se espalham por uma faixa larga de formas reais. O melhor atributo isolado é ip_skew (AUC-ROC 0,972, AUC-PR 0,908). Uma Logística só com IP chega a AUC-PR 0,913, só com DM a 0,350 e com todos os atributos a 0,922, então adicionar DM ao IP quase não acrescenta. A informação de DM existe, mas é não linear: só com DM, a Random Forest chega a 0,782.

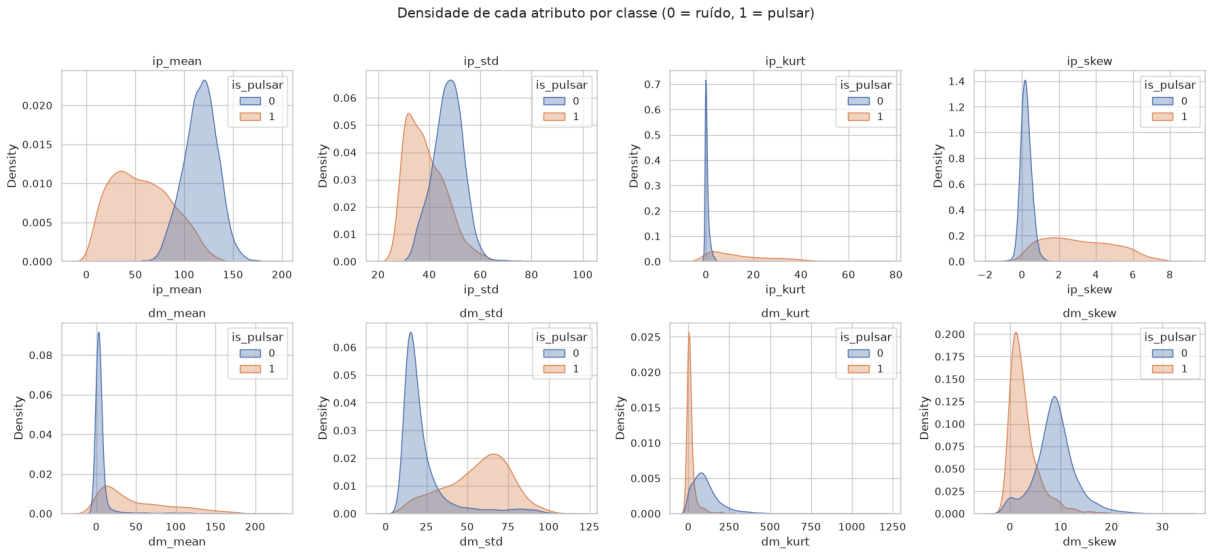


Figura 2 - Densidade de atributo por classe - Fonte: Autoria própria.

Observe que para as métricas IP curtose (ip_kurt) e IP assimetria (ip_skew) o perfil horizontal é pontudo, assim como enunciado na hipótese. A imagem a seguir exibe que ambos os atributos são mais significativos nos pulsares.

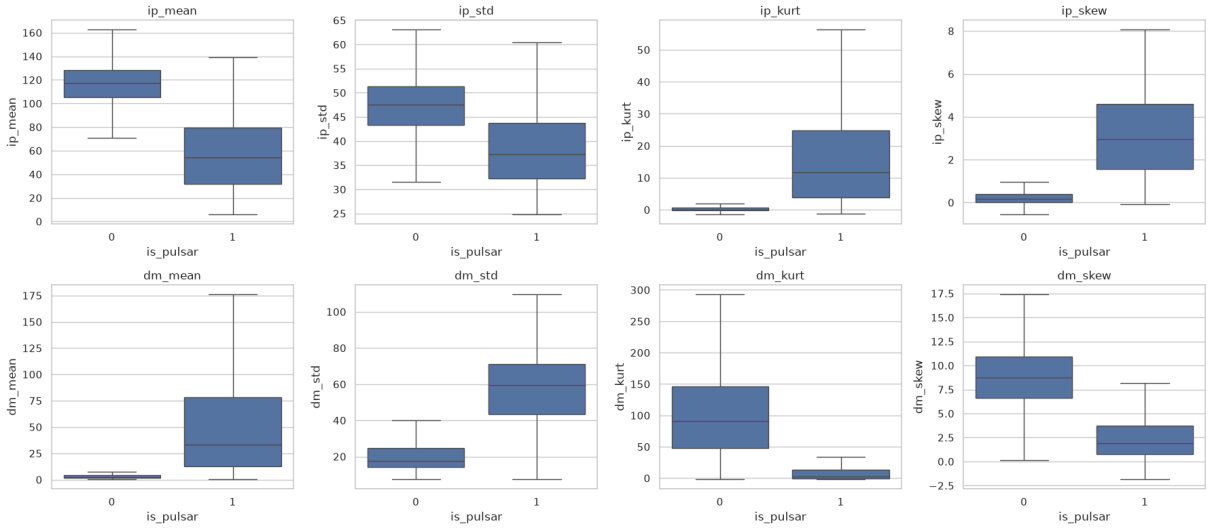


Figura 3 - Valoração de cada atributo por classe - Fonte: Autoria própria

H3: quase linear

O ganho do MLP sobre o SVM linear, +0,005, é menor que o desvio-padrão entre folds (≈ 0,013), então não é significativo. Uma Logística só com a PC1, que não usa rótulos, já atinge AUC-PR 0,842. Uma margem rígida não existe: mesmo com C = 1000 sobram 3.153 violações de margem e 310 erros de treino. Uma árvore de profundidade 3, quase só com `ip_skew` e `dm_std`, tem AUC-ROC 0,976 no teste, o que indica um problema essencialmente unidimensional.

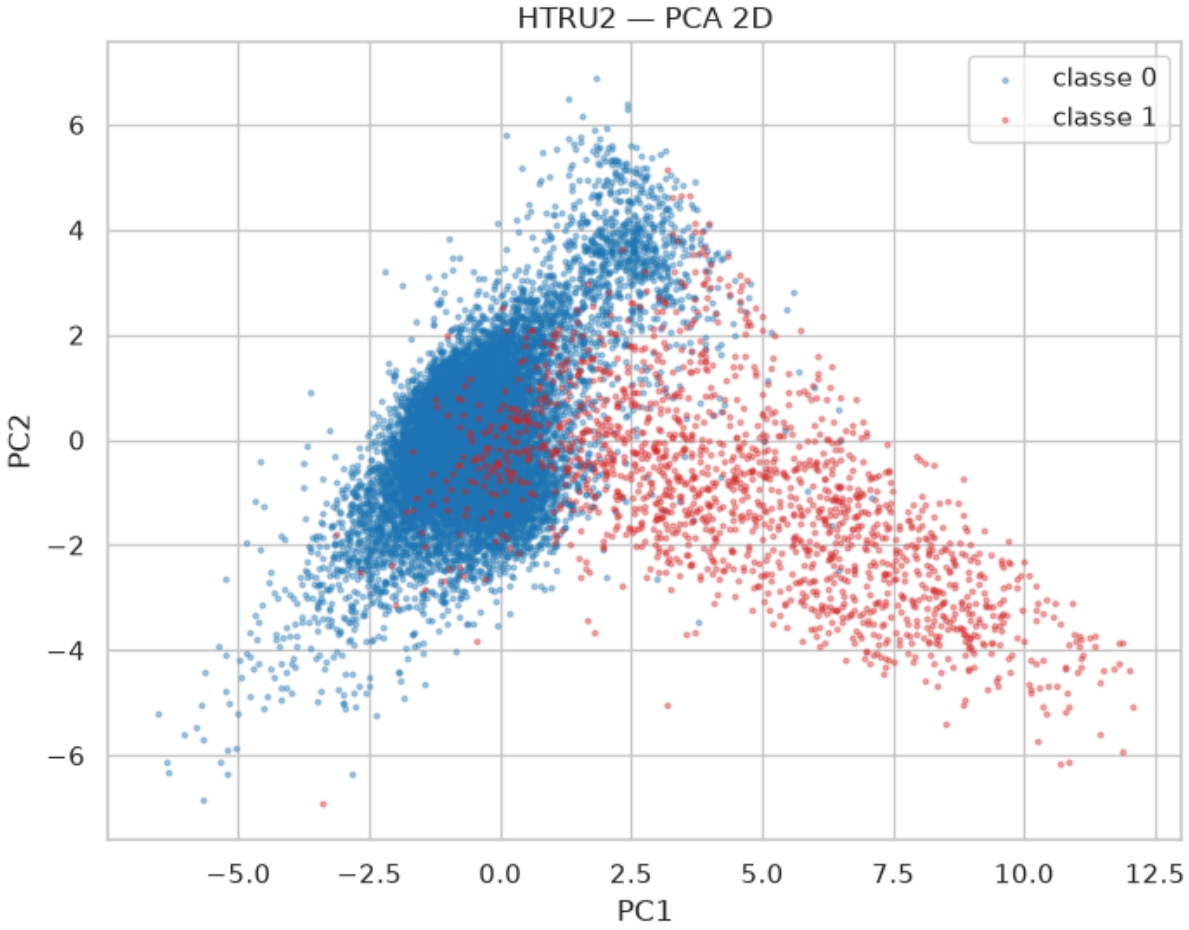


Figura 4 - PCA aplicada aos dados exibindo o grau de separação entre as classes - Fonte: Autoria própria

H4: desbalanceamento e limiar

No limiar padrão, o MLP tem recall 0,835. Ajustando o limiar no treino para recall ≥ 0,95, o recall no teste vai a 0,945, mas a precisão cai para 0,38 e a acurácia para 0,854. Na Logística, `class_weight="balanced"` dá um meio-termo, com recall 0,921 e precisão 0,784. O ponto de operação é uma decisão do problema: um falso positivo custa segundos de inspeção humana, um falso negativo é um pulsar que não será descoberto.

Regressão, Naive Bayes e coeficientes

- **Regressão entre atributos:** prever a curtose a partir da assimetria dá R^2 linear de 0,889 (IP) e 0,845 (DM), contra 0,978 e 0,985 com base polinomial de grau 2. O resíduo linear tem padrão curvo: um r de 0,95 escondia uma relação não linear.
- **Naive Bayes:** é o pior em precisão no teste (0,638, com 161 falsos positivos), porque a independência condicional não vale. O Yeo-Johnson eleva a AUC-PR em validação cruzada de 0,855 para 0,898.

- **Coeficientes:** na Logística completa, ip_skew tem +6,08 e ip_kurt tem −3,05, embora a curtose se associe positivamente a pulsar. É multicolinearidade. Com um representante por par redundante, ip_skew fica em +4,42 e a AUC-PR quase não muda (0,921 vs. 0,922).

Perfil dos erros e melhor modelo

Os falsos negativos têm medianas de ip_skew 0,68 e dm_kurt 69,7, muito mais próximas do ruído (0,18 e 90,2) que dos pulsares detectados (3,59 e 1,4). São pulsares fracos ou atípicos, então o limite está nos dados e não no modelo. No teste, SVM linear e Logística empatam em AUC-PR (0,933), e a Random Forest tem o melhor recall no limiar padrão (0,869, com 43 pulsares perdidos). Pela simplicidade e interpretabilidade, a Logística é a recomendação.

5. Resultados: meteoritos

Duas hipóteses foram refutadas, e ambas só fizeram sentido depois de identificar um confundidor (as campanhas de busca a partir de 1969 e a Antártida).

Hipótese	Resultado	Evidência principal
H1: viés de observação (espaço)	Confirmada	Só 3,4% dos georreferenciados foram vistos caindo, concentrados em regiões povoadas
H1: viés de observação (tempo)	Refutada	Ano mediano 1924 (*Fell*) vs. 1998 (*Found*): efeito oposto ao previsto
H2: cluster antártico	Confirmada	22.096 meteoritos (69%) abaixo de −60°, todos *Found*
H3: *Fell* mais massivos	Confirmada	Massa mediana 2.905 g vs. 278 g fora da Antártida; $p \approx 5 \times 10^{-147}$
H4: metálicos entre os *Found*	Refutada globalmente, confirmada sem Antártida	*Iron* 2,9% vs. 4,4% (global); 8,8% vs. 4,4% (sem Antártida)

H1: o viés existe, mas no sentido oposto no tempo

A hipótese temporal esperava *Fell* mais recentes. A proporção de *Fell* cai de 54% antes de 1900 para 31% em 1900–1968, 5% em 1969–1999 e 1,6% de 2000 em diante. Antes do século XX quase só se conheciam quedas testemunhadas, e a partir de 1969 campanhas sistemáticas na Antártida e nos desertos geram dezenas de milhares de *Found*.

H2: a Antártida

A massa mediana é ≈ 13 g na Antártida contra ≈ 350 g fora dela: fragmentos pequenos, achados porque se destacam no gelo. Como a latitude determina o rótulo sozinha, a Antártida ficou fora da modelagem de fall.



Figura 5 - Distribuição espacial dos meteoritos agregados em fall e fell - Fonte: Autoria própria

H3: massa

Na regressão log10(massa) ~ fell + ano + família, o coeficiente de fell é 0,547 (IC95% 0,47 a 0,62): um meteorito visto caindo tem massa ≈ 3,5× maior, com ano e família constantes. O R^2 de 0,26 é baixo, como esperado, porque a massa depende de fatores ausentes dos dados; o que importa é que sinal e tamanho do efeito se mantêm após o controle. Os metálicos (*Iron*) são ≈ 21× mais massivos que os condritos ordinários.

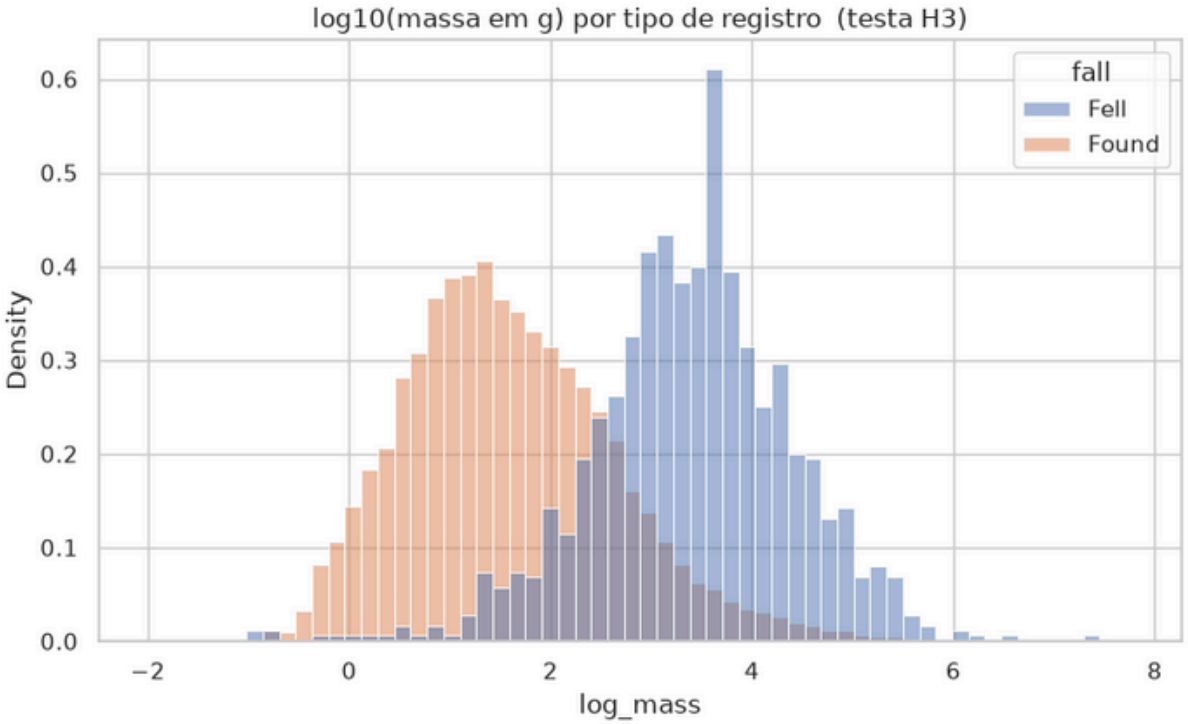


Figura 6 - Registro observado da massa por tipo de registro - Fonte: Autoria própria

H4: paradoxo de Simpson

Globalmente, *Iron* é mais comum entre os *Fell* que entre os *Found*, o oposto do esperado. A coleta antártica, dominada por condritos ordinários pequenos, diluía a proporção de metálicos entre os *Found*. Ao controlar a região, a conclusão se inverte.

Classificação de `fall`: o modelo aprende quem estava olhando

A Random Forest chega a AUC-PR 0,888 (referência aleatória: 0,108) e a Logística a 0,714. A comparação de conjuntos de atributos mostra de onde vem o poder preditivo.

Conjunto de atributos (Random Forest)	AUC-PR
Completo	0,888
Só contexto (ano + local)	0,812
Só meteorito (massa + família)	0,323

Sem o ano, a AUC-PR da Logística cai de 0,714 para 0,459, enquanto a Random Forest compensa com lat/lon (0,858): tempo e espaço são parcialmente substituíveis porque ambos codificam o esforço de busca. Nos odds ratios da Logística, ser *Iron* multiplica a chance de ser *Fell* por 0,021 e cada desvio-padrão a mais no ano por 0,196.

A árvore sobre atributos categóricos confirma o quadro. A entropia de fall fora da Antártida é 0,495 bits, e o ganho de informação é de 0,141 para a época, 0,048 para a faixa de massa, 0,011 para a família e ≈ 0 para o hemisfério. A árvore tem AUC-ROC 0,905 e AUC-PR 0,599, com a regra principal "antes de 1900 e não metálico → *Fell*". A proporção de *Fell* é de 2,9% abaixo de 100g e de 23% acima de 10 kg.

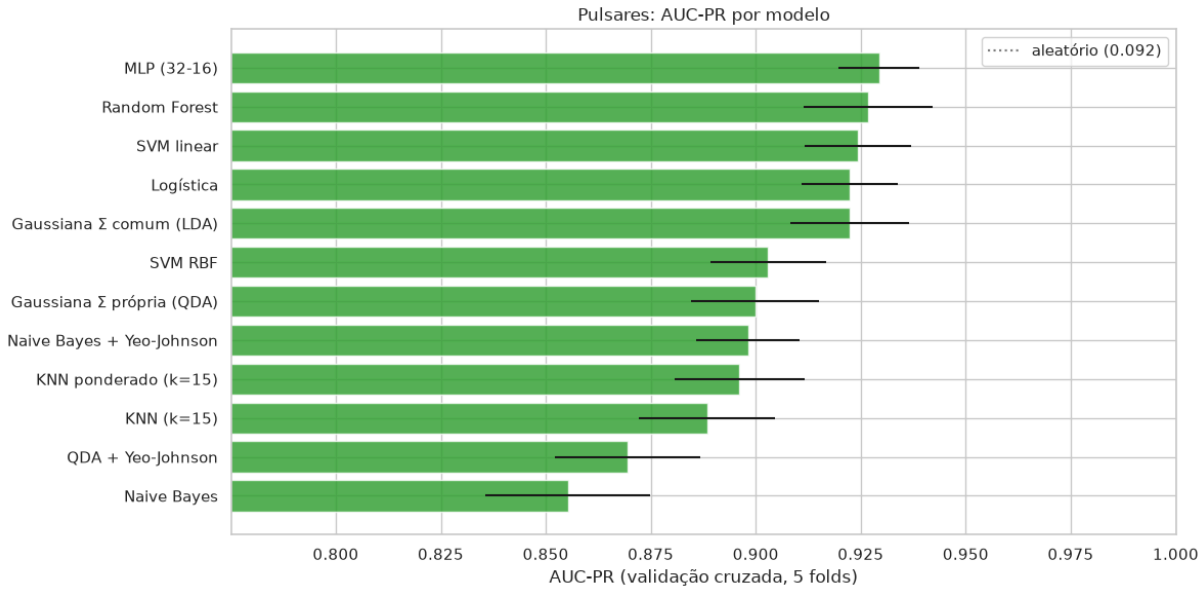


Figura 7 - Performance comparativa entre modelos para a modelagem dos pulsares - Fonte: Autoria própria

6. Discussão

As duas bases ensinam lições diferentes, e a comparação entre elas é o principal resultado do trabalho.

1. **Dois perfis, duas lições.** Em pulsares, o modelo aprende física: a forma do pulso separa sinal de ruído, e o teto de desempenho está em pulsares fracos que os atributos não capturam. Em meteoritos, o modelo aprende a sociologia da observação, e um AUC alto não significa que o fenômeno foi entendido.
2. **Modelos simples bastam quando a estrutura é simples.** Logística e SVM linear empatam com MLP e Random Forest em pulsares. Em meteoritos, árvores ganham com folga porque as regiões de busca são retângulos em lat/lon/ano.
3. **A acurácia engana nas duas bases.** AUC-PR e recall contam a história real, e a escolha do limiar depende do custo de cada erro.
4. **As hipóteses refutadas foram as mais informativas.** A H1 temporal e a H4 global dos meteoritos só ganharam sentido ao identificar o confundidor, o que ilustra o vai e volta entre as etapas 6 e 1 do KDD.

7. Limitações

Os resultados valem para os atributos e as decisões de limpeza adotados aqui, e há três ressalvas a registrar.

- **Agrupamento de `recclass`:** as 8 famílias mineralógicas são uma decisão dos autores, e os resultados por família dependem dela.
- **Atributo mais correlacionado em HTRU2:** pela correlação de Pearson com a classe, o mais correlacionado é `ip_kurt`; pela AUC univariada, o mais informativo é `ip_skew`. As duas métricas medem coisas diferentes e devem ser citadas juntas.
- **Pulsares fracos:** o desempenho de HTRU2 está limitado pelos 8 atributos resumidos. Melhorar exigiria novos atributos extraídos do sinal bruto.

Justificativa de modelos não usados:

- Pulsares, árvores e ensembles: usados só como referência, porque não há atributos categóricos.
- Pulsares, SVM polinomial e sigmoide: o kernel RBF cobre o caso não linear; o polinomial é instável com caudas longas e muito mais lento.
- Pulsares, SVM de margem rígida: não tem solução, porque os dados não são linearmente separáveis (seção A3).
- Pulsares, Softmax e SVM One-vs-One: o problema é binário.
- Meteoritos, SVM, KNN e MLP: os atributos são mistos (one-hot + coordenadas geográficas sem métrica euclidiana natural). As árvores lidam bem com isso e produzem regras legíveis, que são o objetivo do passo 6.
- Meteoritos, PCA: apenas 4 atributos contínuos, de naturezas diferentes (massa, tempo, espaço). Uma combinação linear deles não tem interpretação física.

8. Conclusão

Em pulsares, as quatro hipóteses se confirmaram e um modelo linear simples basta: a Logística (AUC-PR 0,933 no teste) iguala modelos não lineares, e o limite está nos pulsares fracos que os atributos não capturam. Em meteoritos, a Random Forest atinge AUC-PR 0,888, mas 0,812 vem só de ano e local, contra 0,323 de massa e família, de modo que o modelo mede o esforço de observação e não a física dos meteoritos. A H1 temporal e a H4 global foram refutadas e só se esclareceram ao controlar a Antártida e as campanhas pós-1969. A lição geral é que métricas altas precisam de interpretação: o que o modelo aprendeu importa tanto quanto o quanto ele acertou.

9. Referências Bibliográficas

- UCI MACHINE LEARNING REPOSITORY. HTRU2 Data Set. Irvine: University of California, Irvine. Disponível em: https://archive.ics.uci.edu/dataset/372/htru2. Acesso em: 20 out. 2026.
- NASA. Meteorite Landings. NASA Open Data Portal. Arquivo Meteorite_Landings.csv, utilizado no repositório do trabalho.
- AZEVEDO, A.; SANTOS, M. F. KDD, SEMMA and CRISP-DM: a parallel overview.